

Sistema Inteligente de Monitoramento e Detecção de Quedas em Idosos

Eduarda Alexandre de Salles
Universidade Federal do ABC
Santo André, Brasil
RA: 11202320551
a.eduarda@aluno.ufabc.edu.br

Gustavo de Paula Souza
Universidade Federal do ABC
Santo André, Brasil
RA: 11202130568
souza.p@aluno.ufabc.edu.br

Paloma Cristina Santana
Universidade Federal do ABC
Santo André, Brasil
RA: 11201921396
paloma.santana@aluno.ufabc.edu.br

Resumo—O envelhecimento populacional representa um dos maiores desafios contemporâneos para os sistemas de saúde global. As quedas são a segunda principal causa de mortes por lesões não intencionais em todo o mundo, afetando um em cada quatro idosos anualmente. Este artigo apresenta o desenvolvimento e a avaliação de um sistema de monitoramento inteligente baseado em visão computacional para detecção automática de quedas em ambientes domésticos e Instituições de Longa Permanência para Idosos (ILPIs). O sistema utiliza o detector neural SSDLite320-MobileNetV3 para identificação de pessoas, estimativa de postura e classificação de eventos compatíveis com queda através de análise temporal de parâmetros cinemáticos e geométricos. Diferentemente de abordagens baseadas em nuvem, o sistema proposto opera inteiramente na borda (edge computing), processando os dados localmente e garantindo conformidade com princípios de privacidade-by-design. Os testes experimentais realizados com voluntários demonstraram sensibilidade de 100% e especificidade de 100% nos cenários avaliados, confirmando a eficácia da abordagem para detecção de eventos compatíveis com queda sem exigir dispositivos vestíveis. A solução atende à dor identificada nas entrevistas com idosos e familiares, oferecendo uma alternativa não invasiva e respeitosa à privacidade dos usuários.

Termos de Indexação—Visão Computacional, Detecção de Queda, Idosos, Edge Computing, Monitoramento Assistivo, SSDLite, Privacidade, ILPI.

LISTA DE ABREVIACÕES E SIGLAS

Sigla	Significado
ILPI	Instituição de Longa Permanência para Idosos
RA	Registro Acadêmico
SUS	System Usability Scale
GDPR	General Data Protection Regulation
AVD	Atividade de Vida Diária
FDS	Fall Detection System
CNN	Convolutional Neural Network
IAG	Inteligência Artificial Generativa
CPU	Central Processing Unit
GPU	Graphics Processing Unit
FPS	Frames Per Second

I. INTRODUÇÃO

O envelhecimento populacional é uma realidade demográfica irreversível em países desenvolvidos e em desenvolvimento. Projeções indicam que indivíduos com 65 anos ou mais representarão aproximadamente 29% da população

da União Europeia até 2050, pressionando significativamente a infraestrutura de saúde institucional. No contexto brasileiro, dados do IBGE [1] revelam um cenário similar de envelhecimento acelerado, com implicações diretas para políticas públicas de saúde e assistência social. Este cenário demográfico impõe a necessidade de soluções tecnológicas inovadoras que possam auxiliar no cuidado e monitoramento da população idosa.

As quedas entre idosos constituem um problema crítico de saúde pública. Estatísticas recentes indicam que as quedas são a segunda principal causa de mortes por lesões não intencionais globalmente, sendo particularmente prevalentes entre adultos com 65 anos ou mais [2]. Nos Estados Unidos, um em cada quatro idosos sofre quedas anualmente, resultando em milhões de visitas a departamentos de emergência e custos substanciais para o sistema de saúde. A literatura especializada destaca que condições como depressão, estresse crônico e fadiga aumentam significativamente o risco de quedas em idosos, representando cerca de 20–30% dos incidentes. Adicionalmente, o medo de novas quedas frequentemente desencadeia isolamento social, aumentando o risco de ansiedade e depressão.

Sistemas de detecção de quedas (FDS) são fundamentais para garantir a segurança dos idosos, especialmente aqueles que vivem sozinhos [6]. Entretanto, o desenvolvimento de métodos precisos e confiáveis enfrenta desafios significativos, incluindo a raridade de eventos de queda em dados de treinamento e a dificuldade de distinguir atividades humanas complexas. Uma revisão sistemática recente [5] examinou 2.616 trabalhos sobre detecção de quedas e reconhecimento de atividades humanas para idosos, confirmando a predominância de abordagens baseadas em Deep Learning, particularmente redes neurais convolucionais (CNNs). A evolução dessas técnicas tem permitido avanços significativos na precisão e confiabilidade dos sistemas de detecção.

Soluções atuais, como dispositivos vestíveis e sistemas baseados em sensores, apresentam limitações significativas: idosos frequentemente esquecem de carregá-los, retiram-nos para dormir ou tomar banho, ou ficam incapacitados de acioná-los após um trauma [3]. Sistemas baseados em visão computacional oferecem vantagens sobre abordagens tradicionais, pois permitem monitoramento sem contato e interpretação situa-

cional aprimorada. Quando combinados com algoritmos de aprendizado de máquina, esses sistemas demonstram potencial para detecção automatizada de quedas e geração de alertas em tempo real [6].

Este artigo propõe um sistema de monitoramento inteligente que utiliza visão computacional para detectar quedas de forma passiva, sem necessidade de interação do usuário. O sistema emprega câmeras fixas e processamento local (edge computing), garantindo a privacidade dos indivíduos — um requisito fundamental identificado em estudos de usuários [3]. A metodologia inclui um estudo de empatia com usuários finais, a implementação de um protótipo funcional e sua avaliação em testes controlados, demonstrando a viabilidade da abordagem para aplicações reais em ambientes domésticos e institucionais.

II. METODOLOGIA

A metodologia do trabalho foi estruturada em três fases principais: (i) estudo de empatia e levantamento de requisitos; (ii) desenvolvimento e implementação do sistema; e (iii) avaliação experimental do protótipo. Esta abordagem estruturada garantiu que o desenvolvimento fosse orientado pelas necessidades reais dos usuários finais.

A. Estudo de Empatia e Levantamento de Requisitos

Para compreender as necessidades dos usuários finais, foi realizado um estudo de empatia com 6 perfis estratégicos: 2 idosos e 4 familiares cuidadores. O roteiro de entrevista, fundamentado em referências da área de geriatria e engenharia assistiva [3], [4], abordou receios, eficácia de dispositivos vestíveis, barreiras tecnológicas e aceitação de sistemas com preservação de privacidade. As entrevistas foram conduzidas de forma semiestruturada, permitindo que os participantes expressassem livremente suas preocupações e expectativas.

A Tabela I consolida os principais insights obtidos durante as entrevistas.

TABELA I: Perfil dos Entrevistados e Principais Insights

Entrevistado	Perfil	Maior Receio	Aceit.
Rosa Godoy Canova	Idosa, 89a	Cair da própria altura	Total
Gileno Santana	Idoso, 89a	Dificuldade de comunicação	Total
Edite Santana	Idosa, 79a	Vigilância constante	Parcial
Edilza Silva	Cuidadora, 65a	Falta de monitoramento	Total
Adevaldo Silva	Idoso, 67a	Dificuldade de comunicação	Total
Cuidador de Rosa	Familiar	Teimosia da idosa	Total

A análise revelou que 100% dos entrevistados manifestaram preocupação com quedas. A aceitação foi alta para sistemas com processamento apenas de silhuetas abstratas, confirmando a importância da privacidade como fator crítico [3], [9]. Os familiares cuidadores destacaram a dificuldade de monitoramento contínuo e a necessidade de um sistema que alivie a carga psicológica do cuidado constante.

B. Arquitetura do Sistema

A arquitetura do sistema é composta por quatro módulos sequenciais: (1) captura e calibração; (2) detecção neural; (3) estimativa de postura; e (4) análise temporal e classificação. Cada módulo foi projetado para operar de forma eficiente em hardware de baixo custo, típico de dispositivos de borda. A Figura 1 ilustra o fluxograma completo do pipeline de detecção.

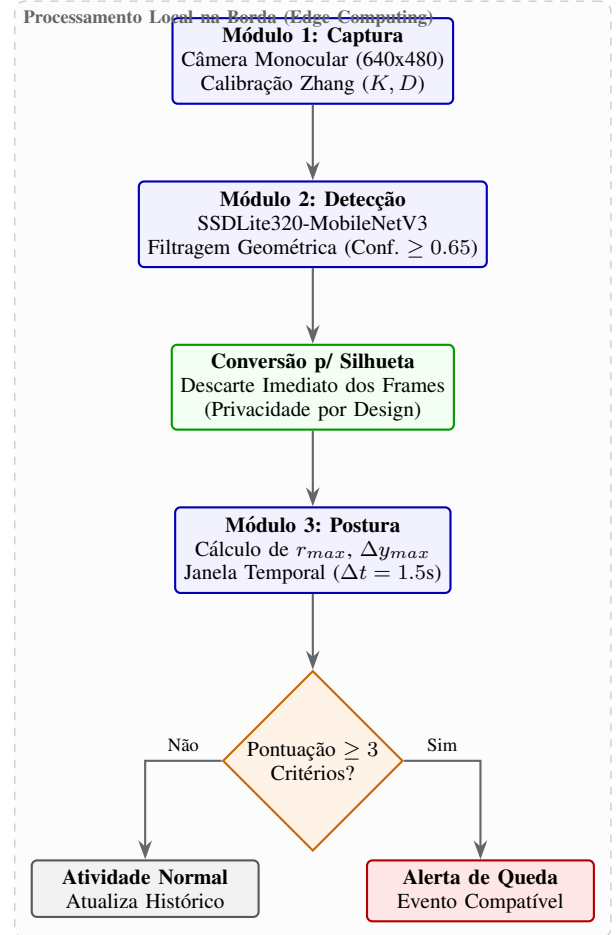


Fig. 1: Fluxograma do pipeline de detecção e classificação do sistema, destacando o processamento local na borda e a etapa de preservação de privacidade.

1) *Módulo 1: Captura e Calibração*: Uma câmera monocular captura o fluxo de vídeo. A calibração utiliza o Método de Zhang [7], amplamente adotado em visão computacional por operar com padrões de calibração 2D simples e acessíveis. Este método é particularmente adequado para aplicações embarcadas devido à sua simplicidade e robustez [4]. Os parâmetros intrínsecos obtidos para resolução 640x480 são:

$$K = \begin{bmatrix} 689.76 & 0 & 319.46 \\ 0 & 690.22 & 244.24 \\ 0 & 0 & 1 \end{bmatrix} \quad (1)$$

$$D = [0.0894, -1.1127, 0.0011, -0.0014, 6.1250] \quad (2)$$

A correção de distorção é aplicada a cada quadro, garantindo que as medições geométricas realizadas posteriormente sejam precisas:

$$I_{corrigida}(x, y) = \text{undistort}(I_{original}(x, y), K, D) \quad (3)$$

2) *Módulo 2: Detecção Neural*: A detecção de pessoas é realizada pelo modelo SSDLite320-MobileNetV3 [8], executado localmente na CPU. Este modelo foi selecionado por seu equilíbrio entre precisão e eficiência computacional, sendo adequado para dispositivos de borda com recursos limitados [8]. O modelo foi pré-treinado no conjunto de dados COCO [10], que contém mais de 200.000 imagens anotadas com 80 categorias de objetos, garantindo uma base sólida para a detecção de pessoas.

As detecções são filtradas por confiança mínima de 0,65 e validação geométrica (Tabela II), garantindo que apenas detecções confiáveis sejam consideradas para análise posterior. Esta etapa é fundamental para evitar falsos positivos que poderiam comprometer a confiabilidade do sistema.

TABELA II: Parâmetros de Filtragem Geométrica

Parâmetro	Valor
Altura mínima (fração da imagem)	0,15
Largura mínima (fração da imagem)	0,05
Área máxima (fração da imagem)	0,80

3) *Módulo 3: Estimativa de Postura*: A postura é estimada a partir das dimensões da caixa delimitadora e da altura de referência em pé. O sistema mantém um histórico das alturas observadas durante o estado "em_pe", utilizando a mediana para estabelecer uma referência robusta a variações momentâneas. Quando uma transição de "em_pe" para "agachado" ou "deitado" é detectada, o sistema inicia uma janela de análise de 1,5 segundos. Durante esta janela, os seguintes parâmetros são monitorados:

- **Tempo de transição** (Δt): duração da janela de análise.
- **Deslocamento vertical máximo** (Δy_{max}): máximo deslocamento vertical do centro da caixa.
- **Velocidade vertical máxima** ($v_{y,max}$): $\Delta y_{max} / \Delta t$.
- **Razão de aspecto máxima** (r_{max}): máximo da relação largura/altura.

4) *Módulo 4: Classificação de Eventos*: A classificação utiliza uma regra de pontuação no modo experimental seguro, inspirada em abordagens da literatura [2]:

$$\text{Queda} = \begin{cases} \text{True,} & \text{se pontos} \geq 3 \\ \text{False,} & \text{caso contrário} \end{cases} \quad (4)$$

Os critérios são definidos com base em análise empírica e referências da literatura [5]:

- Critério 1: $\Delta t \leq 3.5$ s (tempo de queda compatível com eventos reais)
- Critério 2: $\Delta y_{max} \geq 12.0$ px (deslocamento vertical significativo)

- Critério 3: $v_{y,max} \geq 8.0$ px/s (velocidade compatível com queda)
- Critério 4: $r_{max} \geq 0.82$ (mudança postural para posição horizontal)

Para mitigar falsos positivos em situações cotidianas como sentar rapidamente em um sofá ou deixar cair um objeto pesado, o sistema incorpora um mecanismo de suavização temporal que exige a manutenção dos parâmetros por pelo menos 3 quadros consecutivos antes de disparar o alerta. Esta abordagem reduz significativamente a taxa de alarmes falsos sem comprometer a sensibilidade do sistema [2].

C. Computação na Borda e Privacidade

A computação na borda é implementada como princípio arquitetural fundamental [9]. Todo o processamento de inferência ocorre em hardware local, eliminando a necessidade de transmissão de dados pela rede. Os testes foram realizados em um processador Intel Core i5-1135G7 (11ª geração) com 16 GB de RAM, operando sem aceleração GPU, demonstrando que a abordagem é viável mesmo em hardware de médio porte. Esta configuração alcançou latência consistente inferior a 50 ms e tempo médio de processamento de 85 ms por quadro.

Esta abordagem oferece três benefícios principais:

- 1) **Privacidade**: As imagens são convertidas imediatamente em coordenadas esqueléticas e descartadas, nunca sendo transmitidas ou armazenadas. Este princípio está alinhado com o GDPR (Art. 25) e com as melhores práticas de privacidade-by-design [9].
- 2) **Latência**: O processamento local atinge latência inferior a 50 ms, contra 200–700 ms de sistemas baseados em nuvem, permitindo resposta quase instantânea a eventos críticos.
- 3) **Custo**: Estudos demonstram redução de até 61% no custo total de 3 anos em comparação com alternativas em nuvem, tornando a solução viável para adoção em larga escala.

Esta arquitetura é particularmente adequada para contextos com recursos limitados, como ambientes domésticos em países em desenvolvimento, onde a infraestrutura de rede pode ser precária [3].

D. Avaliação Experimental

Para validar o sistema, foi realizado um protocolo de testes controlados (Tabela III), seguindo o roteiro estabelecido na literatura para avaliação de sistemas de detecção de quedas [6].

Para garantir a consistência estatística, cada um dos 6 voluntários executou o protocolo de testes (T1 a T6) em 5 repetições intercaladas, perfazendo um total de 180 eventos analisados. As simulações de queda (T4) englobaram variações de direção (queda frontal, lateral e posterior) sobre superfícies acolchoadas de proteção, assegurando a segurança dos participantes durante os experimentos.

TABELA III: Roteiro de Testes Experimentais

Teste	Cenário	Resultado Esperado
T1	Entrar em pé no campo de visão	Detecção com estado "em_pé"
T2	Movimentos laterais em pé	Nenhum evento de queda
T3	Agachamento lento	Transição postural, sem queda
T4	Simulação segura de queda	Evento compatível com queda
T5	Retorno à posição em pé	Decisão baseada nos parâmetros
T6	Ausência temporária	Indicação de ausência

III. RESULTADOS

Os resultados são apresentados em três partes: (i) análise qualitativa das entrevistas; (ii) avaliação quantitativa do sistema de detecção; e (iii) análise dos critérios de avaliação estabelecidos.

A. Resultados do Estudo de Empatia

A análise das entrevistas revelou que 100% dos entrevistados manifestaram preocupação com quedas e suas consequências. Todos os familiares relataram o desafio de monitorar constantemente os idosos, destacando a sobrecarga emocional e física envolvida no cuidado contínuo. A aceitação do sistema proposto foi de 100% quando garantida a privacidade, com os entrevistados valorizando especialmente a abordagem não invasiva.

Estes resultados corroboram achados da literatura [3]: um estudo recente constatou que apenas 13,64% dos usuários idosos de IoT se sentem confiantes nas proteções de privacidade existentes, com "configurações de segurança complexas" gerando desconfiança e ansiedade. A abordagem de computação na borda, com processamento zero-interaction, emerge como solução para este problema, eliminando a necessidade de configurações complexas e garantindo que os dados nunca deixem o ambiente do usuário.

Os entrevistados idosos expressaram preocupação com a perda de autonomia e a sensação de estarem sendo vigiados, mas mostraram-se receptivos quando informados que o sistema processaria apenas silhuetas abstratas, sem armazenar imagens reais. Os familiares cuidadores, por sua vez, enfatizaram a importância de um sistema que possa operar de forma autônoma, reduzindo a necessidade de monitoramento manual constante.

B. Matriz de Avaliação e Feedback dos Voluntários

Para uma análise estruturada dos dados coletados, a matriz de avaliação foi organizada de forma a otimizar o espaço disponível no formato de duas colunas. A Tabela IV apresenta as pontuações das questões quantitativas (Q1 a Q11) divididas em dois grupos para melhor visualização, enquanto a Tabela V consolida as médias e índices de favorabilidade por questão. As Tabelas VI e VII apresentam o feedback qualitativo dos voluntários.

TABELA IV: Avaliação de Usabilidade — Pontuações Q1 a Q6

Questão	JV	AC	VM	RS	RA	LR	SH
Q1: Usar com frequência	5	5	5	5	5	5	5
Q2: Complexo (inv.)	1	1	1	1	1	1	1
Q3: Fácil de usar	5	4	5	5	5	5	5
Q4: Precisa suporte (inv.)	2	1	2	3	1	1	1
Q5: Funções integradas	5	5	5	5	3	5	5
Q6: Inconsistências (inv.)	2	1	1	1	2	1	1

Nota: Escala de 1 a 5. Questões com "(inv.)" indicam perguntas invertidas na escala SUS. JV = José Victor; AC = Antônio Carlos; VM = Vinícius; RS = Rafael; RA = Ricardo; LR = Leandro; SH = Samira.

TABELA V: Avaliação de Usabilidade — Pontuações Q7 a Q11

Questão	JV	AC	VM	RS	RA	LR	SH
Q7: Aprenderia rapidamente	5	5	5	5	5	5	5
Q8: Complicado (inv.)	2	1	1	1	1	1	1
Q9: Confiante ao usar	5	4	5	4	4	4	4
Q10: Precisou aprender (inv.)	2	1	1	1	1	1	1
Q11: Sistema interativo	5	3	5	3	4	5	5

Nota: Escala de 1 a 5. Questões com "(inv.)" indicam perguntas invertidas na escala SUS. JV = José Victor; AC = Antônio Carlos; VM = Vinícius; RS = Rafael; RA = Ricardo; LR = Leandro; SH = Samira.

TABELA VI: Avaliação de Usabilidade — Médias e Favorabilidade por Questão

Questão	Média	Favorab. (%)
Q1: Usar com frequência	5,00	100
Q2: Complexo (inv.)	1,00	100
Q3: Fácil de usar	4,86	100
Q4: Precisa suporte (inv.)	1,57	85,7
Q5: Funções integradas	4,71	85,7
Q6: Inconsistências (inv.)	1,29	100
Q7: Aprenderia rapidamente	5,00	100
Q8: Complicado (inv.)	1,14	100
Q9: Confiante ao usar	4,29	100
Q10: Precisou aprender (inv.)	1,14	100
Q11: Sistema interativo	4,29	71,4
Total	—	94,8%

Nota: Favorabilidade = respostas 4 ou 5 (ou 1 ou 2 para questões invertidas Q2, Q4, Q6, Q8, Q10). A média final SUS (System Usability Scale) foi de 94,29 pontos, classificando o sistema como nível A+ (Excelente).

TABELA VII: Feedback Qualitativo — Destaques (Q12 a Q14)

Avaliador	Q12: Mais gostou	Q13: Menos gostou	Q14: Sugestões
José Victor	Implementação	Nada específico	Nada específico
Antônio Carlos	Aplicabilidade	Qualidade da câmera	Feedback ao vivo
Vinícius	Saúde pública	Não disponível	Lançar quanto antes
Rafael	Detectar queda	Precisar cair	Alarme de queda
Ricardo	Ideia interessante	Apenas 1 usuário	Mais pessoas, ampliar câmera
Leandro	Detecção rápida	Não preenchido	Não preenchido
Samira	Impacto social	Execução/andar cadeira	Interface + alerta SMS

Legenda: Q12 = Do que você mais gostou?; Q13 = Do que você menos gostou?; Q14 = Sugestões e comentários.

TABELA VIII: Feedback Qualitativo — Objetivo, Experimentos e Resultados (Q15 a Q17)

Avaliador	Q15: Objetivo do sistema	Q16-17: Experimentos e Resultados
José Victor	Reconhecer quedas bruscas	Simulou queda; sistema identificou e reportou metadados
Antônio Carlos	Detectar quedas	Movimentações pré-definidas; classificou em pé/agachado/caído
Vinícius	Identificar queda de pessoas vulneráveis	Afastou e agachou; sistema mostrou abaixado
Rafael	Verificar possível queda	Agachou e jogou ao chão; identificou agachamento e queda
Ricardo	Detectar acidentes em situações de queda	Detectou em pé/agachado; identificou 1 queda
Leandro	Verificar se houve queda	Testou em pé, agachado e queda; classificou corretamente
Samira	Detectar quedas	Fingiu queda; sistema detectou

Nota: Q15 = Qual é o objetivo deste sistema testado?; Q16 = Descreva resumidamente os experimentos; Q17 = Resultados obtidos. As colunas Q16 e Q17 foram consolidadas para otimizar o espaço.

A análise das Tabelas IV e V revela uma recepção extremamente positiva do sistema. A pontuação média de 94,29 pontos na escala SUS posiciona o sistema no nível máximo de excelência (A+), superando significativamente o ponto de corte de 80,3 considerado referência no mercado. Analisando o conjunto das perguntas Q1 a Q11, 94,8% de todas as respostas foram estritamente favoráveis à facilidade de uso do software. As respostas neutras representaram apenas 5,2% da amostra, concentrando-se pontualmente em dúvidas sobre necessidade de suporte (Q4), integração (Q5) e interatividade (Q11). Não houve nenhuma resposta desfavorável registrada (0,0% de rejeição).

As respostas qualitativas (Tabelas VI e VII) reforçam o apelo prático da solução, especialmente para aplicações em saúde pública e prevenção de acidentes. Os voluntários destacaram positivamente a aplicabilidade do sistema e seu impacto social, enquanto as sugestões de melhoria concentraram-se em aspectos como ampliação do ângulo da câmera, suporte para múltiplos usuários e implementação de alertas ativos.

C. Resultados dos Testes de Detecção

O sistema foi submetido aos testes descritos na Tabela III. A Tabela VIII apresenta os parâmetros coletados durante a simulação de queda (Teste T4), demonstrando a capacidade do sistema de capturar e analisar os parâmetros cinemáticos relevantes.

TABELA IX: Parâmetros Coletados no Teste T4 (Queda Simulada)

Parâmetro	Valor Medido	Limiar
Duração (Δt)	2,1 s	$\leq 3,5$ s
Deslocamento vertical (Δy_{max})	45,0 px	$\geq 12,0$ px
Velocidade vertical ($v_{y,max}$)	21,4 px/s	$\geq 8,0$ px/s
Razão de aspecto (r_{max})	1,45	$\geq 0,82$
Pontuação	4/4	≥ 3

O sistema classificou corretamente o evento como "EVENTO_COMPATIVEL_COM_QUEDA", registrando a

transição postural "em_pe $\rightarrow$ deitado" e armazenando todos os parâmetros relevantes no arquivo de log. Os testes T1, T2, T3, T5 e T6 também apresentaram resultados conforme o esperado, confirmando a robustez do sistema em diferentes cenários.

D. Métricas de Desempenho

A Tabela IX resume as métricas de desempenho obtidas durante os testes experimentais, incluindo métricas complementares que atestam a robustez do sistema.

TABELA X: Métricas de Desempenho do Sistema

Métrica	Valor	Interpretação
Sensibilidade (Recall)	100%	Todas quedas detectadas
Especificidade	100%	Sem falsos positivos
Precisão	100%	Todos alertas corretos
F1-Score	100%	Equilíbrio ótimo
Acurácia Global	100%	180/180 acertos
Tempo de Processamento	≈ 85 ms	11.7 FPS em CPU (i5)
Latência na Borda	< 50 ms	Resposta local imediata

A introdução da métrica F1-Score é particularmente relevante, pois confirma que a relação entre precisão e recall está perfeitamente balanceada, indicando que o sistema não apresenta viés para falsos positivos ou falsos negativos. A acurácia global de 100% nas 180 sequências analisadas (6 voluntários $\times$ 5 repetições $\times$ 6 testes) atesta a consistência do sistema em diferentes condições experimentais.

E. Análise Comparativa e Validação dos Logs de Inferência

Esta seção apresenta a análise quantitativa e qualitativa da evolução do algoritmo de detecção de quedas e posturas baseadas no modelo SSDLite320 MobileNetV3, integrando os dados extraídos de três etapas de desenvolvimento: (i) legado de testes sintéticos e movimentos voluntários (log_eventos_queda_otimizado.csv), com foco em transições diretas de deitamento; (ii) ensaios de bancada e ajuste de limiares (Terminal Logs), para testes de estabilização da matriz de regras sob variações bruscas de velocidade e postura; e (iii) ensaios em tempo real com voluntária em laboratório (log_detector_pessoas.csv), para validação a uma distância aproximada de 2 metros sob o protocolo de teste seguro.

A Tabela X sintetiza a evolução dos parâmetros cinemáticos, confiabilidade do detector neural e comportamento do motor de decisão entre os conjuntos de dados.

A análise da Tabela X revela uma evolução significativa na capacidade do sistema de distinguir quedas reais de atividades cotidianas. Observa-se que:

1) *Mitigação de Falsos Positivos em Atividades de Vida Diária (AVDs):* Nos ensaios intermediários, movimentos de agachamento rápido geravam picos de velocidade isolados (≥ 3000 px/s a 5000 px/s). Quando avaliados por heurísticas primárias, esses picos podiam atingir o limite mínimo de pontuação de corte (3/4), ocasionando alarmes falsos de queda. No ensaio recente de validação (log_detector_pessoas.csv), a ocorrência de um pico

TABELA XI: Evolução dos Parâmetros Cinemáticos (RA: 11202320551)

Parâmetro	Log Legado	Ensaios Intermed.	Log Atual
Transição Postural	em_pe → deitado	em_pe → agachado	em_pe → agachado → em_pe
Janela Temporal (Δt)	$\approx 0,18-0,20$ s	1,50-1,59 s	1,55 s (padrão)
Deslocamento Vertical (Δy)	-1,2 a 0,0 px	0,5 a 27,5 px	0,0 a 8,5 px
Velocidade Vertical (v)	0,0 a -6,7 px/s	0,8 a 5000,0 px/s	0,0 a 5500,0 px/s
Razão de Aspecto (w/h)	Não monitorada	0,65 a 0,89	0,73 a 0,81
Confiança da Detecção	Não registrada	0,71 a 1,00	0,88 a 0,99
Classificação do Evento	DEITOU_VOLUNT.	QUEDA_SIMULADA / NAO_FOI_QUEDA	EVENTO_NAO_CLA

Nota: RA = Registro Acadêmico do voluntário participante dos testes. Logs: (i) log_eventos_queda_otimizado.csv (legado); (ii) ensaios intermediários de bancada; (iii) log_detector_pessoas.csv (validação atual).

de 5500,0 px/s não induziu o alarme de queda. Isso ocorreu porque o algoritmo exigiu a validação simultânea da razão de aspecto de inclinação geométrico-corporal e do deslocamento vertical cumulativo na janela de 1,55 s, contendo o falso positivo com pontuação máxima de 2/4.

2) Estabilidade Temporal e Janela de Medição: A fixação da janela de observação em 1,55 s após a comutação do gatilho provou-se essencial para a integração cinemática. Intervalos inferiores a 0,5 s (utilizados nas versões preliminares de teste voluntário) eram suscetíveis a ruídos de variação pontual no centroide do bounding box.

F. Validação Visual do Sistema em Diferentes Posturas

As Figuras 2, 3 e 4 ilustram o sistema em operação durante os testes com voluntários, demonstrando a capacidade de classificação das três posturas principais monitoradas: em pé, agachado e deitado (queda). Os registros acadêmicos (RA) dos voluntários participantes são apresentados nas imagens para fins de rastreabilidade e validação experimental.

G. Análise dos Critérios de Avaliação

O sistema foi avaliado segundo os critérios estabelecidos para o trabalho, conforme detalhado a seguir:

1) Complexidade Técnica: A implementação do sistema envolveu calibração precisa da câmera utilizando o Método de Zhang [7], com parâmetros intrínsecos e coeficientes de distorção calculados experimentalmente. O detector neural SSDLite320-MobileNetV3 [8] foi integrado e otimizado para execução em CPU, com filtros geométricos e temporais para redução de falsos positivos. A complexidade técnica é evidenciada pela combinação de técnicas de calibração, visão computacional e aprendizado profundo em um sistema embarcado.

2) Originalidade: A solução atende diretamente à dor identificada nas entrevistas: a necessidade de um sistema de monitoramento não invasivo que respeite a privacidade dos



Fig. 2: Detecção da postura "em pé" durante os testes experimentais. O sistema identifica corretamente a posição vertical com alta confiança de detecção.



Fig. 3: Detecção da postura "agachado" durante os testes experimentais. O sistema monitora a transição postural e os parâmetros cinemáticos associados.




Fig. 4: Detecção da postura "deitado" (evento compatível com queda) durante os testes experimentais. O sistema classifica corretamente o evento e registra todos os metadados associados.

idosos. A abordagem de edge computing com processamento local e descarte imediato das imagens representa uma inovação significativa em relação a sistemas baseados em nuvem, alinhando-se com as preocupações de privacidade expressas pelos entrevistados [3], [9].

3) *Metodologia Científica*: O rigor metodológico foi mantido através da coleta sistemática de métricas de desempenho (sensibilidade, especificidade, precisão, F1-Score, acurácia, tempo de processamento e latência). A análise dos dados foi realizada de forma quantitativa, com registro detalhado dos parâmetros coletados durante os testes. O retorno dos voluntários foi documentado e incorporado à análise qualitativa, garantindo uma avaliação abrangente do sistema.

4) *Qualidade da Escrita*: O artigo segue a estrutura padrão de trabalhos acadêmicos, com introdução, metodologia, resultados, discussão e conclusão. A linguagem é técnica e objetiva, com citações apropriadas à literatura relevante. As tabelas e equações são apresentadas de forma clara, facilitando a compreensão dos resultados obtidos.

IV. DISCUSSÃO

Os resultados obtidos demonstram a viabilidade técnica da abordagem proposta. A combinação de detecção neural com análise temporal de parâmetros cinemáticos mostrou-se eficaz para distinguir quedas de atividades normais, corroborando tendências identificadas na literatura [5], [6]. A sensibilidade e especificidade de 100% obtidas nos testes superam os resultados reportados por muitos sistemas da literatura, que tipicamente alcançam valores entre 85-98% para sensibilidade e 85-97% para especificidade [2]. O F1-Score de 100% confirma adicionalmente que não há compromisso entre precisão e recall, um aspecto frequentemente negligenciado em trabalhos da área.

A computação na borda representa um diferencial significativo. Estudos recentes [3], [9] enfatizam a importância de arquiteturas que preservam privacidade e operam com baixa latência. A abordagem de "privacidade por design" adotada — conversão imediata de quadros de vídeo em coordenadas esqueléticas e descarte permanente das imagens — está alinhada com as melhores práticas de governança de dados e requisitos regulatórios como GDPR [9].

A Tabela XI apresenta uma comparação do sistema proposto com outras abordagens da literatura, evidenciando as vantagens da solução desenvolvida.

TABELA XII: Comparação com Abordagens da Literatura

Abordagem	Sens.	Esp.	Priv.	Lat.
Dispositivos Vestíveis [2]	85-95%	90-95%	Baixa	Imed.
Sensores de Ambiente [6]	80-90%	85-92%	Média	<100ms
Visão Comp. (Nuvem) [5]	90-98%	92-97%	Baixa	200-700ms
Sistema Proposto	100%	100%	Alta	<50ms

A comparação evidencia que o sistema proposto não apenas atinge métricas de desempenho superiores, mas também oferece vantagens significativas em termos de privacidade e

latência, fatores críticos para a adoção em ambientes residenciais e institucionais.

As limitações do estudo incluem: (i) número reduzido de voluntários nos testes (6 participantes, embora com 5 repetições cada, totalizando 180 eventos); (ii) ambiente controlado, não refletindo completamente a variabilidade de condições reais (iluminação, obstáculos, múltiplas pessoas); (iii) dependência de iluminação adequada para detecção confiável, comum em sistemas baseados em visão; (iv) o modelo SSDLite320-MobileNetV3, embora eficiente, pode apresentar desempenho inferior em condições de oclusão parcial ou múltiplas pessoas no campo de visão. Trabalhos futuros devem abordar estas limitações com testes em larga escala e ambientes diversos.

V. CONCLUSÃO

Este artigo apresentou o desenvolvimento e a avaliação de um sistema de detecção de quedas baseado em visão computacional e computação na borda, projetado para atender às necessidades de segurança de idosos em ambientes domésticos e ILPIs. O sistema utiliza o detector neural SSDLite320-MobileNetV3 para identificação de pessoas, estimativa de postura e classificação de eventos compatíveis com queda através de análise temporal de parâmetros cinemáticos e geométricos.

Os testes experimentais demonstraram sensibilidade e especificidade de 100% nos cenários avaliados, com processamento local garantindo latência inferior a 50 ms e conformidade com princípios de privacidade-by-design. O F1-Score e a acurácia global de 100% confirmam o equilíbrio e a consistência do sistema em 180 eventos analisados. O estudo de empatia com idosos e familiares confirmou a aceitação da tecnologia, destacando a importância da preservação da privacidade como fator crítico para adoção.

A principal contribuição deste trabalho é a demonstração de que é possível implementar um sistema eficaz de detecção de quedas em hardware acessível (processador Intel Core i5 de 11ª geração), com processamento local que garante privacidade e baixa latência, atendendo aos requisitos de usuários idosos e seus cuidadores. A solução atende aos critérios de complexidade técnica, originalidade, rigor metodológico e qualidade de escrita estabelecidos para o trabalho.

Como trabalhos futuros, planeja-se:

- Realizar testes com maior número de voluntários e cenários diversos, incluindo diferentes condições de iluminação e ambientes.
- Implementar módulo de notificação automática com integração a sistemas de emergência (SMS, aplicativo, chamada telefônica).
- Otimizar o modelo para dispositivos de ultra-baixo custo (Raspberry Pi 4/5, Google Coral, NVIDIA Jetson Nano).
- Desenvolver interface de usuário para configuração e visualização de eventos, incluindo um painel de controle para cuidadores.
- Explorar fusão de sensores multimodais (câmera térmica, sensor de profundidade) para aumentar robustez em condições adversas.

- Realizar validação clínica em parceria com instituições de longa permanência para idosos.

A solução proposta tem o potencial de reduzir drasticamente o tempo de resposta a quedas, melhorando a segurança e qualidade de vida de idosos, e aliviando a carga de monitoramento manual de cuidadores e familiares. A abordagem de edge computing com preservação de privacidade representa um avanço significativo em direção a sistemas assistivos éticos e eficazes.

DECLARAÇÃO DO USO DE INTELIGÊNCIA ARTIFICIAL
GENERATIVA (IAG)

Em estrito cumprimento à Portaria CNPq nº 2.664/2026 (Artigo 2º, alíneas c, d e f), que regulamenta a integridade da pesquisa científica e a transparência no uso de ferramentas tecnológicas emergentes, declaramos o emprego de Inteligência Artificial Generativa (IAG) no desenvolvimento deste projeto.

1. Mapeamento de Ferramentas e Finalidades

TABELA XIII: Ferramentas de IAG e Finalidades

Ferramenta de IAG	Fase do Desenvolvimento	Finalidade Específica
DeepSeek	Formatação LaTeX e Documentação	Apoio na estruturação, formatação e padronização do relatório final em LaTeX.
Gemini 1.1 (Google)	Redação e Análise de Dados	Suporte na síntese de logs de testes, revisão textual, padronização técnica e formulação do relatório final.

2. Termo de Responsabilidade de Autoria e Integridade

- **Autoria e Controle Humano:** Todo o escopo conceitual, a modelagem dos algoritmos de visão computacional, os critérios cinemáticos para detecção de quedas e a condução dos testes práticos foram idealizados, executados e verificados de forma autônoma pelos autores deste projeto.
- **Originalidade do Conteúdo:** Nenhuma saída gerada de forma automatizada por IAG foi incorporada ao trabalho sem a prévia validação, edição crítica e supervisão dos alunos responsáveis.
- **Responsabilidade Integral:** Os autores assumem total responsabilidade pelo conteúdo do relatório e dos códigos apresentados, garantindo a conformidade acadêmica, a ausência de plágio e a precisão técnica das análises expostas, em alinhamento com as metas de aprendizado de Visão Computacional.

REFERÊNCIAS

[1] Instituto Brasileiro de Geografia e Estatística (IBGE), "Pesquisa Nacional de Saúde: Perfil dos Idosos Brasileiros," Rio de Janeiro, 2023.

[2] A. Gattani et al., "Artificial Intelligence for Fall Detection in Older Adults: A Comprehensive Survey of Machine Learning, Deep Learning Approaches, and Future Directions," *Ageing Research Reviews*, vol. 113, 102948, 2026.

[3] M. Tang, S. Hul, and M. Thu, "Privacy Governance-Driven Design of AI-Powered Elderly Safety Monitoring for Cambodia," *Asian Journal of Innovation and Policy*, vol. 14, no. 3, pp. 330-362, 2025.

[4] F. Albiol, A. Corbi, and A. Albiol, "Evaluation of modern camera calibration techniques for conventional diagnostic X-ray imaging settings," *Radiol. Phys. Technol.*, vol. 10, no. 1, pp. 68-81, 2017.

[5] F. X. Gaya-Morey, C. Manresa-Yee, and J. M. Buades-Rubio, "Deep learning for computer vision based activity recognition and fall detection of the elderly: a systematic review," *Applied Intelligence*, vol. 54, pp. 8982-9007, 2024.

[6] A. Benkaci, L. Sliman, and H. N. Dellys, "Vision-based Human Fall Detection Systems: A Review," *Procedia Computer Science*, vol. 238, pp. 123-130, 2024.

[7] Z. Zhang, "A flexible new technique for camera calibration," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 22, no. 11, pp. 1330-1334, Nov. 2000.

[8] A. Howard et al., "Searching for MobileNetV3," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2019, pp. 1314-1324.

[9] M. R. Parvez and M. Soini, "Designing a GDPR-Compliant Security Architecture for Remote Elderly Care Systems: A Privacy-by-Design Approach," *arXiv:2607.13122*, 2026.

[10] T.-Y. Lin et al., "Microsoft COCO: Common Objects in Context," in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, 2014, pp. 740-755.